

Predicciones

Predicciones

Procesos estocásticos con tendencia determinística

Tendencia Lineal

Modelo AR(1)

Predicción

Resultados

Tendencia cíclica

Modelo MA(1)

Modelo AR(2)

Modelo ARMA(2,1)

Predicción

Resultados

Modelo ARIMA(2,1,1)

Procesos estocásticos con tendencia determinística

Supongamos el proceso Y formado por una componente estocástica X y una tendencia determinística μ , de la forma:

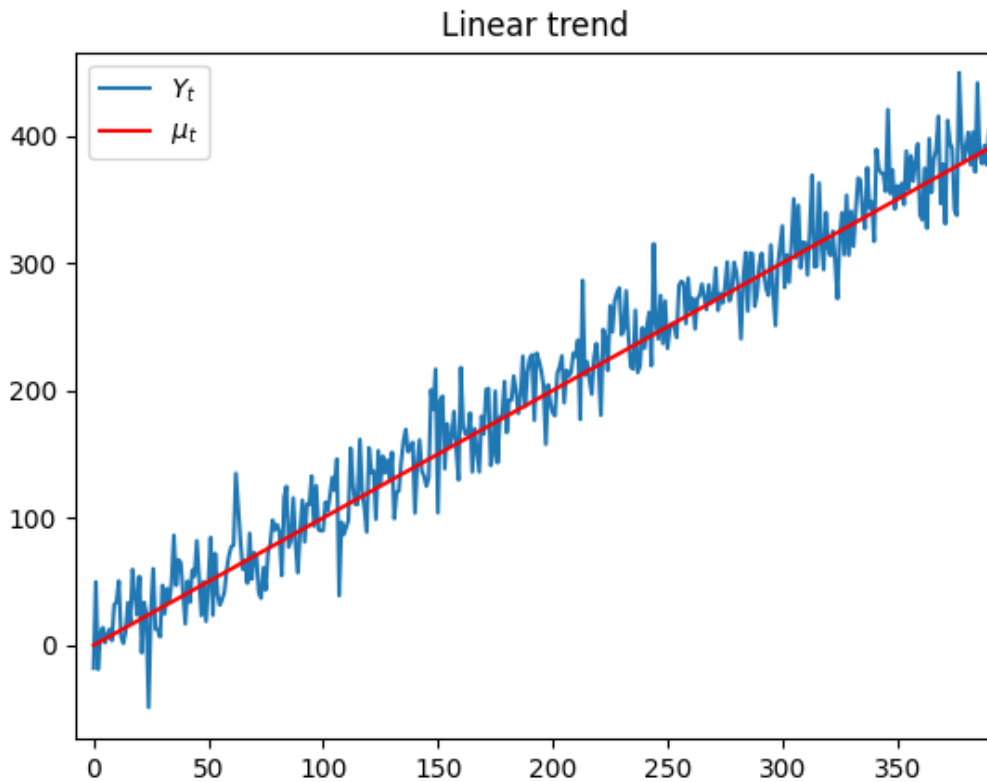
$$Y_t = X_t + \mu_t$$

Como hemos visto la tendencia puede tener distintas representaciones:

$$\text{Tendencia determinística } \mu_t := \begin{cases} \text{Constante} & \mu_t = \mu \\ \text{Lineal} & \mu_t = \beta_0 + \beta_1 t \\ \text{Cuadrática} & \mu_t = \beta_0 + \beta_1 t + \beta_2 t^2 \\ \text{Cíclica} & \mu_t = \mu_{t-T} \\ \text{Senoidal} & \mu_t = \beta \cos(\omega t + \phi) \end{cases}$$

Tendencia Lineal

```
N=1000
mu=np.arange(0,N)
X=np.random.normal(5,25,N)
Y=X+mu
plt.plot(Y)
plt.plot(mu,color='red')
plt.title("Linear trend")
plt.legend(['$Y_t$', '$\mu_t$'])
plt.show()
```



Modelo AR(1)

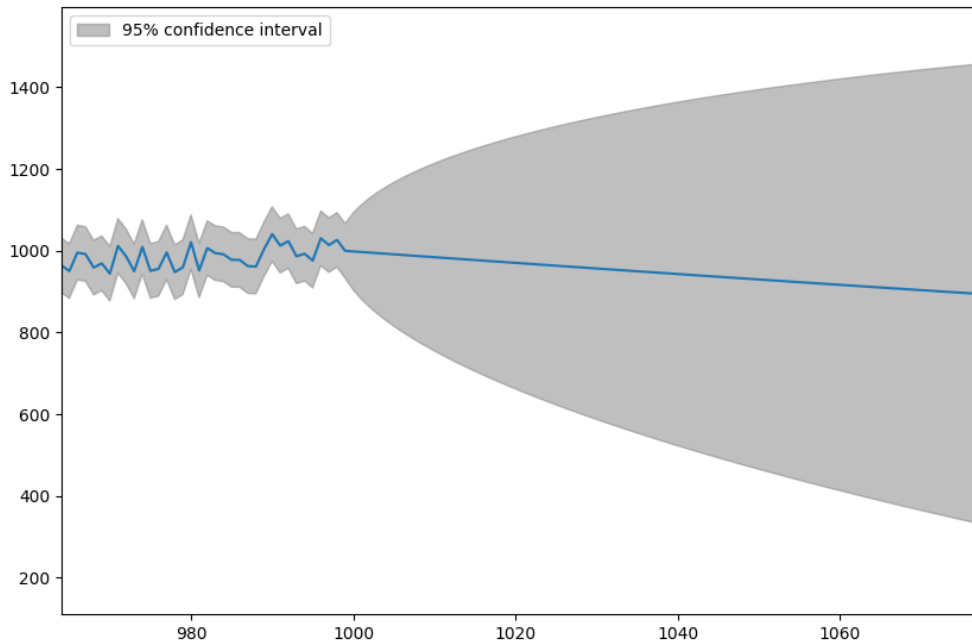
```
from statsmodels.graphics.tsaplots import plot_predict
from statsmodels.tsa.arima_process import arma_generate_sample
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_squared_error

ar1 = ARIMA(Y, order=(1, 0, 0), trend="n")
ar1_res = ar1.fit()
print(ar1_res.summary())
```

```
1 SARIMAX Results
2 =====
3 Dep. Variable: y No. Observations: 1000
4 Model: ARIMA(1, 0, 0) Log Likelihood: -4950.416
5 Date: mar, 16 nov 2021 AIC: 9904.832
6 Time: 14:11:27 BIC: 9914.647
7 Sample: 0 HQIC: 9908.562
8 - 1000
9 Covariance Type: opg
10 =====
11 coef std err z P>|z| [0.025 0.975]
12 -----
13 ar.L1 0.9986 0.002 649.713 0.000 0.996 1.002
14 sigma2 1160.9614 50.960 22.782 0.000 1061.082 1260.841
15 =====
16 Ljung-Box (L1) (Q): 276.92 Jarque-Bera (JB): 0.49
17 Prob(Q): 0.00 Prob(JB): 0.78
18 Heteroskedasticity (H): 1.08 Skew: 0.04
19 Prob(H) (two-sided): 0.49 Kurtosis: 3.08
20 =====
```

Predicción

```
fig, ax = plt.subplots(figsize=(10, 8))
fig = plot_predict(ar1_res, start=1, end=2000, ax=ax)
legend = ax.legend(loc="upper left")
plt.show()
```



Resultados

Lo que se observa es que a medida que aumenta el largo de la predicción aumenta también el intervalo de confianza del 95%, haciendo que la predicción acumule error. Esto se puede ver con la forma general del proceso ARIMA. Si $\Psi_1, \Psi_2, \dots, \Psi_{l-1}$ son los coeficientes del proceso, se puede observar que la varianza de la predicción del proceso AR(1) es:

$$\text{var}(e_t(\ell)) = \sigma_e^2(1 + \Psi_1^2 + \Psi_2^2 + \dots + \Psi_{\ell-1}^2)$$

es decir que la varianza aumenta a medida que se agregan términos de predicción o bien aumenta ℓ . Para el caso AR1 además se puede usar el resultado de la serie geométrica y ver que:

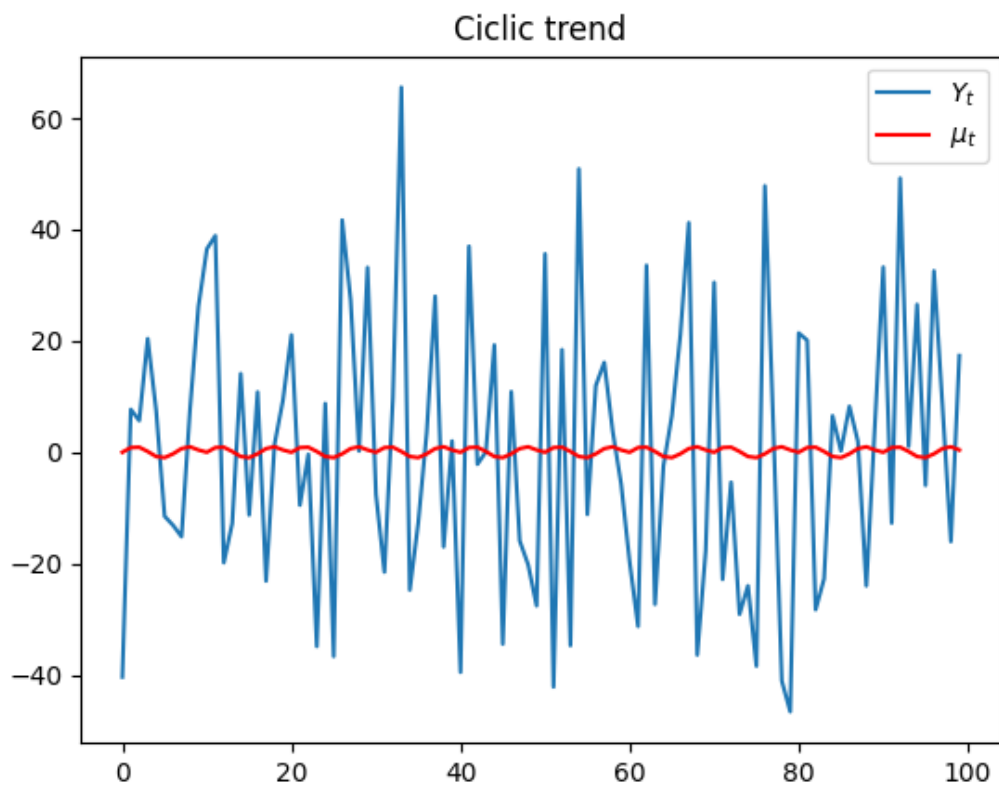
$$\text{var}(e_t(\ell)) = \sigma_e^2 \left(\frac{1 - \phi^{2\ell}}{1 - \phi^2} \right)$$

cuando el retardo ℓ es muy largo, se puede aproximar y ver que el resultado es la autocovarianza de Y .

$$\text{var}(e_t(\ell)) \approx \left(\frac{\sigma_e^2}{1 - \phi^2} \right) \approx \text{var}(Y_t) = \gamma_0$$

Tendencia cíclica

```
n=100
N=10000
mu=np.repeat(np.sin(np.arange(n)),int(N/n))
X=np.random.normal(5,25,int(N))
Y=X+mu
plt.plot(Y)
plt.plot(mu,color='red')
plt.title("Ciclic trend")
plt.legend(['$Y_t$', '$\mu_t$'])
plt.show()
```



Modelo MA(1)

```
# MA(1)
N =1000
b1 =0.25
e_t0 = np.random.normal(0,1)
e_t1 = np.random.normal(0,1)
y = np.append(e_t0,b1*e_t0+e_t1) # y1 = b1*e_t0+e_t1

for i in range(N):
    e_t0 = e_t1
    e_t1 = np.random.normal(0,1)
    y = np.append(y,b1*e_t0+e_t1)

y.mean()
```

```


y.std()
plt.plot(y);plt.show()

# Predict
ma1 = ARIMA(y, order=(0, 0, 1))
ma1_res = ma1.fit()
print(ma1_res.summary())

fig, ax = plt.subplots(figsize=(10, 8))
fig = plot_predict(ma1_res, start=1, end=1010, ax=ax)
plt.plot(y)
legend = ax.legend(loc="upper left")
plt.show()

y_ma1=y

```



Modelo AR(2)

```

N=1000
a1=0.4
a2=0.35
x=np.arange(2)
e_t=np.random.normal(0,1)
y=np.append(x,a1*x[1]+a2*x[0]+e_t)

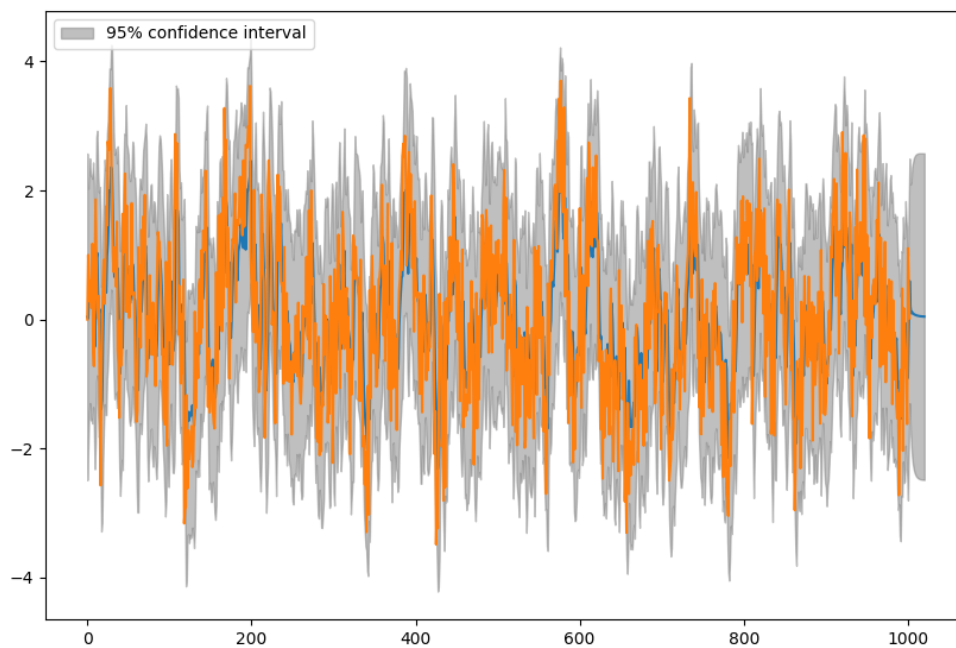
for i in range(N):
    e_t=np.random.normal(0,1)
    y=np.append(y,a1*y[-1]+a2*y[-2]+e_t)

y.mean()
y.std()
#plt.plot(y);plt.show()

```

```
# Predict
l=20
ar2 = ARIMA(y, order=(2, 0, 0))
ar2_res = ar2.fit()
print(ar2_res.summary())

fig, ax = plt.subplots(figsize=(10, 8))
fig = plot_predict(ar2_res, start=0, end=N+l, ax=ax)
plt.plot(y)
legend = ax.legend(loc="upper left")
plt.show()
```



Modelo ARMA(2,1)

```
#ARMA

N=10000
a1=0.4
a2=0.3
b1 = -0.3

x=np.arange(2)
e_t=np.random.normal(0,1)
y=np.append(x,a1*x[1]+a2*x[0]+e_t)

for i in range(N):
    e_0 = e_t
    e_t=np.random.normal(0,1)
    y=np.append(y,a1*y[-1]+a2*y[-2]+ b1*e_0 + e_t)
```

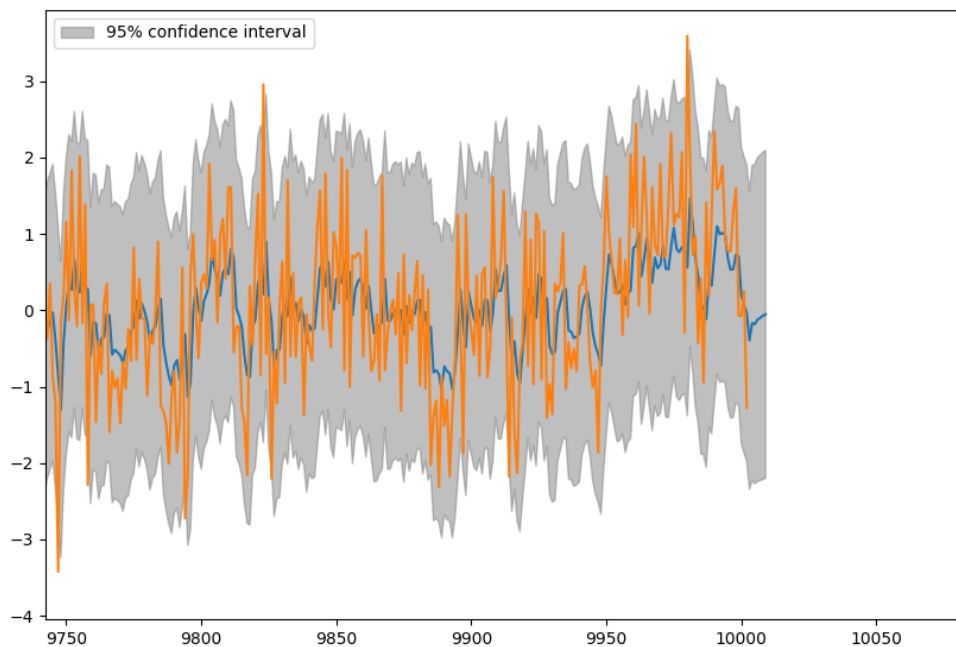
```
y.mean()
y.std()
plt.plot(y);plt.show()
```

Predicción

```
# Predict
y_arma = ARIMA(y, order=(2, 0, 1))
y_arma_res = y_arma.fit()
print(y_arma_res.summary())

fig, ax = plt.subplots(figsize=(10, 8))
fig = plot_predict(y_arma_res, start=1, end=N+10, ax=ax)
plt.plot(y)
legend = ax.legend(loc="upper left")
plt.show()
```

Resultados



Modelo ARIMA(2,1,1)

```
#ARIMA

N=10000
a1=0.35
a2=0.25
b1 =-0.35

x=np.arange(2)
e_t=np.random.normal(0,1)
y=np.append(x,a1*x[1]+a2*x[0]+e_t)

for i in range(N):
    e_0 = e_t
    e_t=np.random.normal(0,1)
    y=np.append(y,a1*y[-1]+a2*y[-2]+ b1*e_0 + e_t)

t = np.arange(int(N*0.01), step=0.01)
y=y[2:N+2]

y = y+t
y.mean()
y.std()
#plt.plot(y);plt.show()

# Predict
y_arma = ARIMA(y, order=(2, 1, 1), trend='t')
y_arma_res = y_arma.fit()
print(y_arma_res.summary())

fig, ax = plt.subplots(figsize=(10, 8))
fig = plot_predict(y_arma_res, start=1,end=N+10, ax=ax)
plt.plot(y)
legend = ax.legend(loc="upper left")
plt.show()
```